Classificação de Imagens de Sensoriamento Remoto

Do pixel ao mapa temático: métodos, algoritmos e avaliação da acurácia

Disciplina de Sensoriamento Remoto | Graduação | Prof. Hatan Pinheiro | Dia 2

Roteiro da aula

- Da imagem ao mapa temático: o que é classificar
- Espaço de atributos e separabilidade espectral
- Classificação não supervisionada: K-médias
- Classificação supervisionada: amostras e algoritmos
- Abordagem por pixel e por objeto (GEOBIA)
- Avaliação da acurácia: matriz de confusão e índices
- Atividade prática: classificação no QGIS com o dzetsaka

Retomando o Dia 1

- **Assinatura espectral:** cada alvo reflete de forma distinta ao longo do espectro
- **Bandas:** o sensor registra a reflectância em faixas discretas (B02 a B12 no Sentinel-2)
- **NDVI:** combina vermelho (B04) e IV próximo (B08) para destacar a vegetação
- **Ponte para hoje:** se os alvos diferem espectralmente, é possível separá-los de forma automática

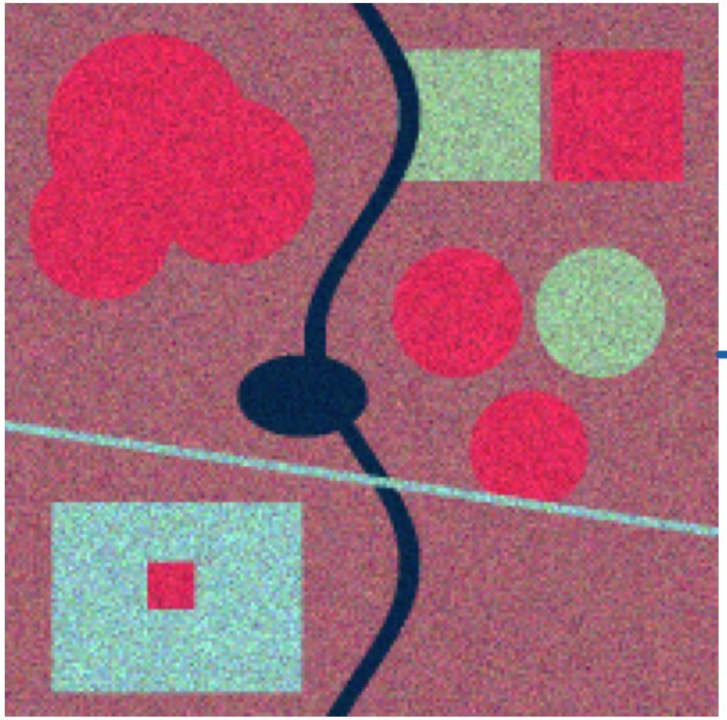
O que é classificação de imagens

- **Definição:** atribuir cada pixel (ou objeto) a uma classe temática
- **Entrada:** valores de reflectância em várias bandas, e eventualmente índices e textura
- **Saída:** mapa temático de cobertura e uso da terra
- **Fundamento:** alvos distintos ocupam regiões distintas do espaço de atributos
- **Produtos:** mapas de vegetação, de áreas urbanas, de corpos d'água, de mudanças no território

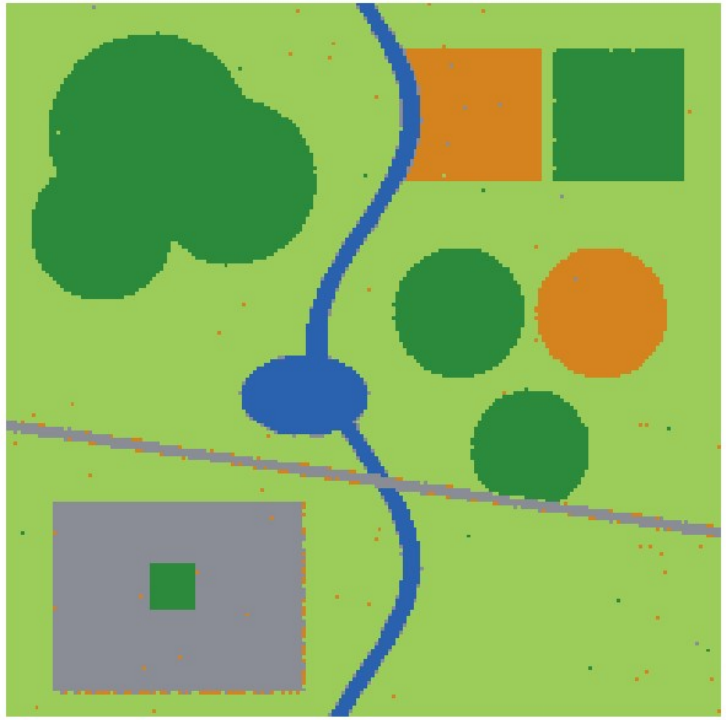
Da imagem ao mapa temático

Classificação: de valores de reflectância a classes temáticas

Imagem (falsa-cor: B08, B04, B03)

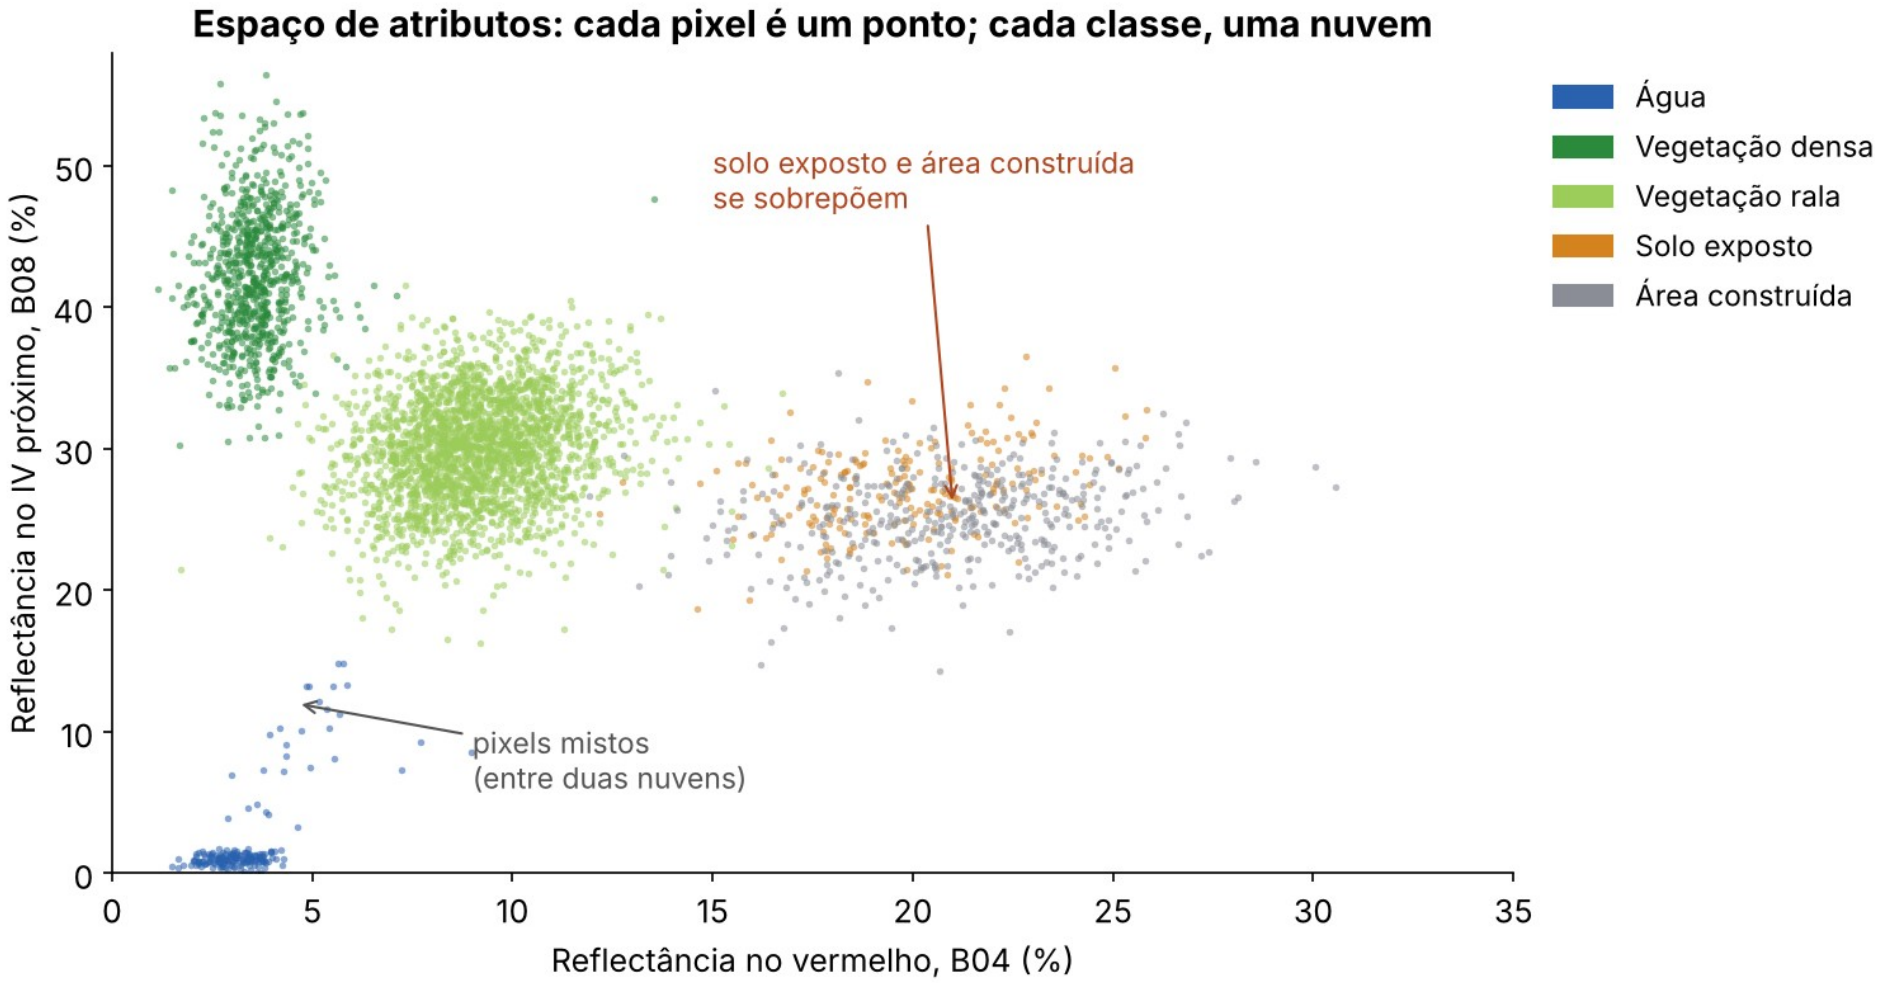


Mapa temático (classificado)



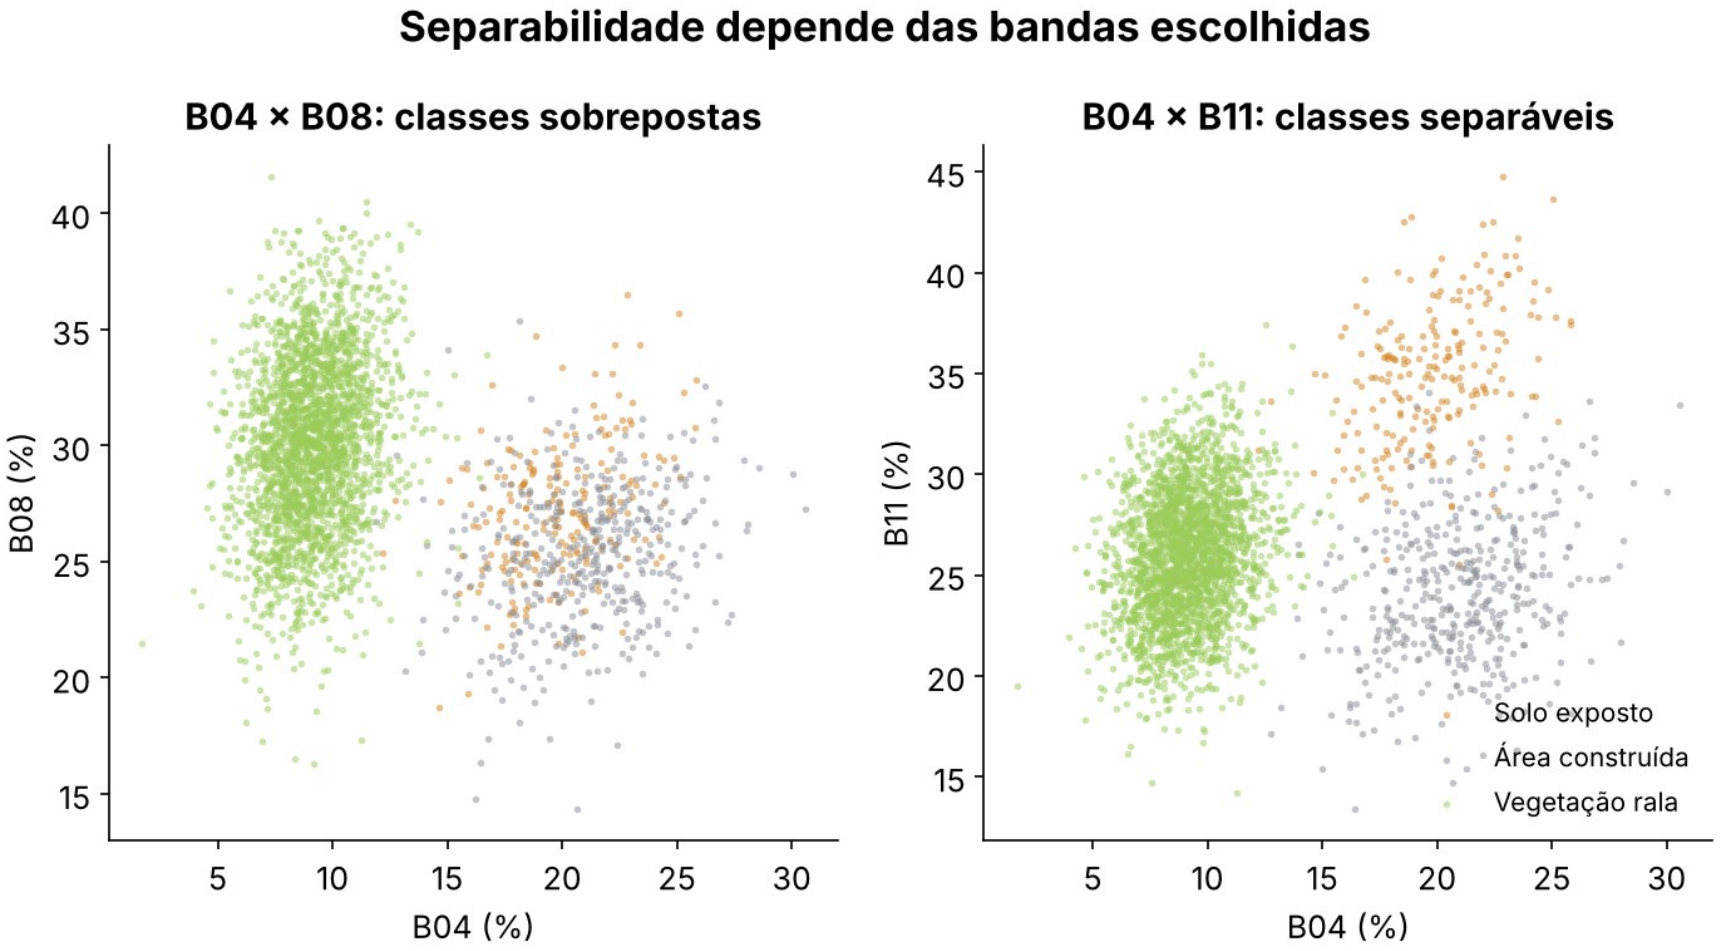
Cena sintética (200 × 200 pixels de 10 m) gerada para fins didáticos; classificação por máxima verossimilhança.

Espaço de atributos



Valores ilustrativos, gerados para fins didáticos.

Separabilidade espectral



Valores ilustrativos; B11 = infravermelho de ondas curtas (SWIR).

Duas abordagens de classificação

NÃO SUPERVISIONADA

O algoritmo agrupa os pixels por semelhança espectral, sem amostras prévias (ex.: K-médias, ISODATA). O analista nomeia os grupos depois. Útil para exploração e quando não há dados de campo.

SUPERVISIONADA

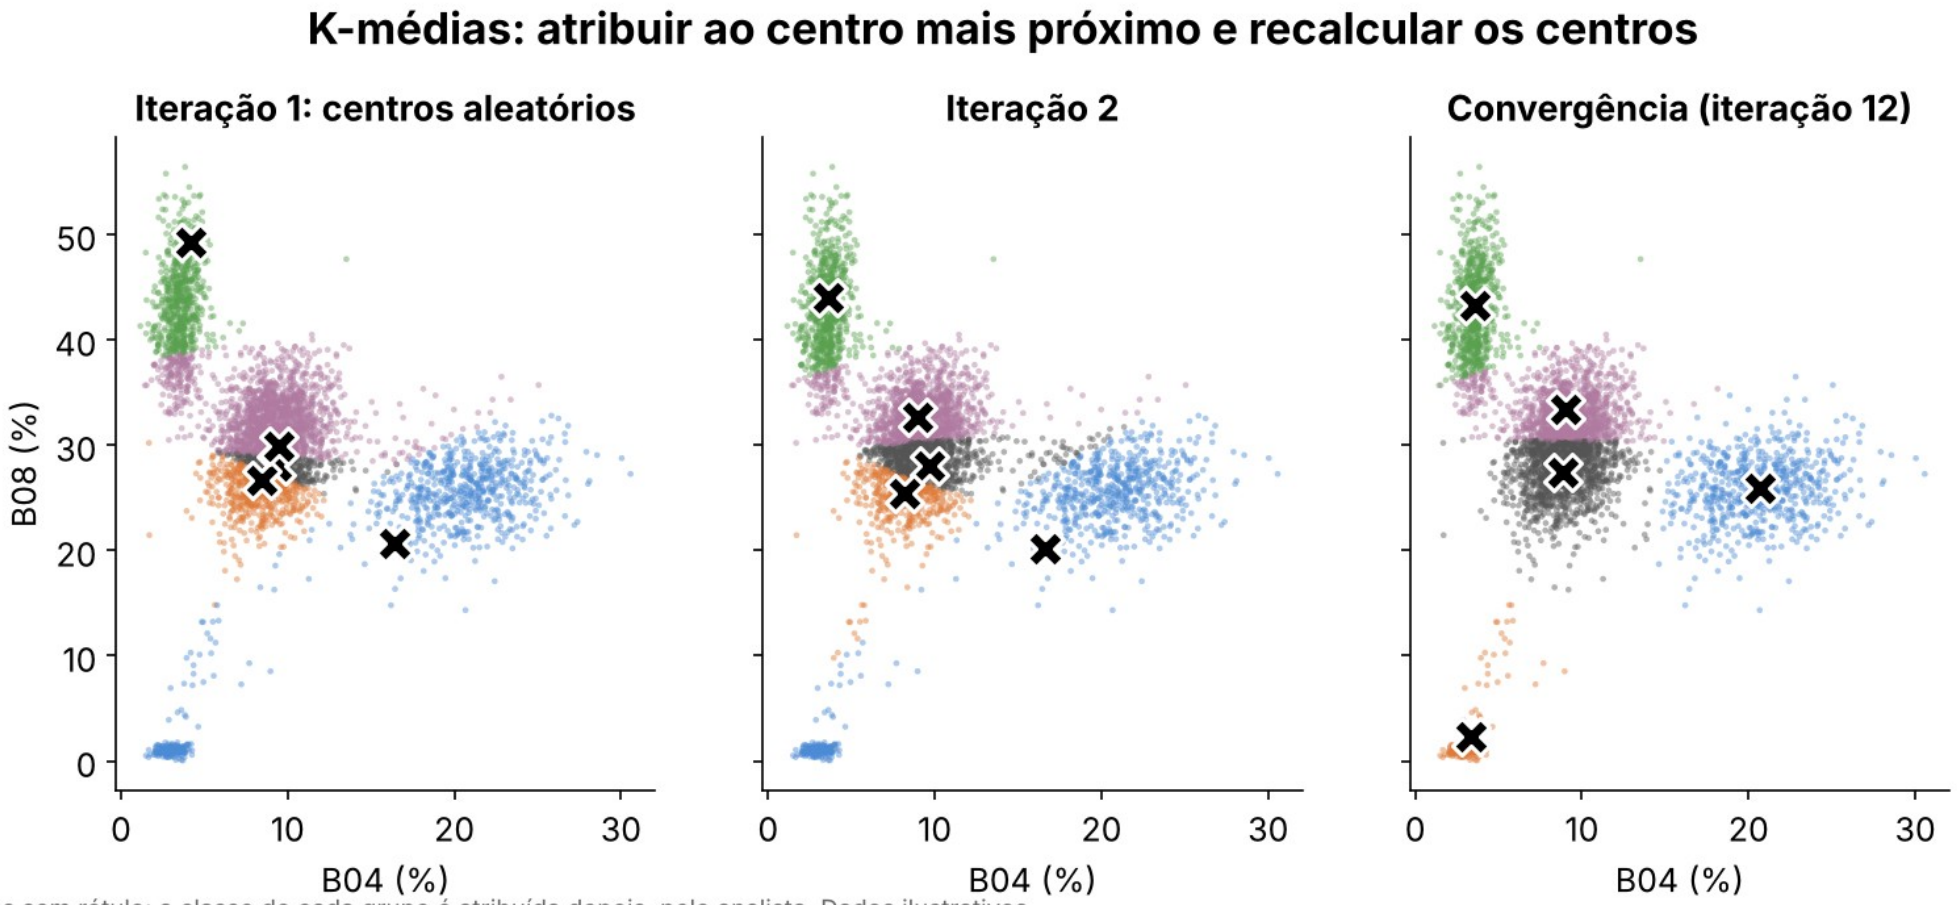
O analista fornece amostras de treinamento de cada classe; o algoritmo aprende a regra de decisão e a aplica a toda a imagem (ex.: distância mínima, máxima verossimilhança, Random Forest).

EM COMUM

Ambas dependem da separabilidade das classes no espaço de atributos e exigem avaliação da acurácia do resultado.

Síntese: a diferença central está em quando entra o conhecimento do analista — antes (supervisionada) ou depois (não supervisionada) do agrupamento.

Não supervisionada: K-médias



Agrupamentos sem rótulo: a classe de cada grupo é atribuída depois, pelo analista. Dados ilustrativos.

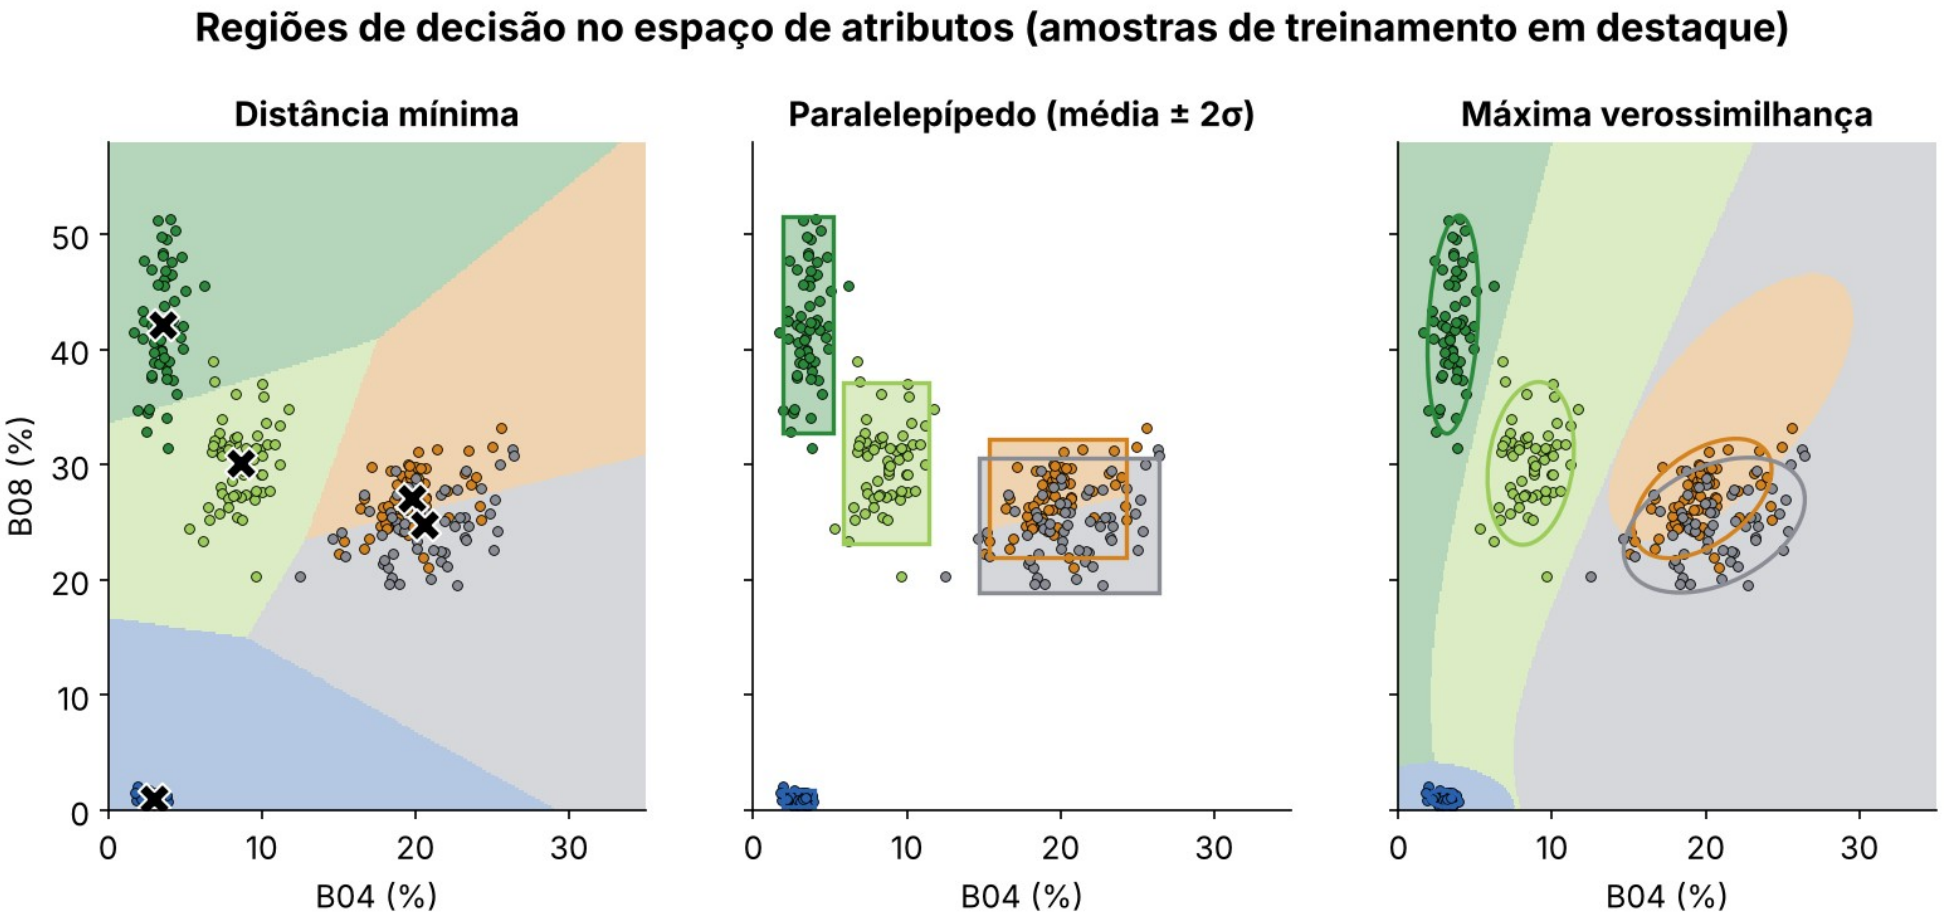
Supervisionada: amostras de treinamento

- **Representatividade:** cobrir a variação interna de cada classe (sol, sombra, umidade)
- **Quantidade:** número suficiente de pixels por classe; classificadores estatísticos estimam médias e covariâncias
- **Distribuição:** amostras espalhadas pela cena, não concentradas em um único polígono
- **Pureza:** evitar bordas e pixels mistos
- **Independência:** separar amostras de treinamento e de validação

Classificadores clássicos

- **Distância mínima:** atribui o pixel à classe de média mais próxima; simples, ignora a variância
- **Paralelepípedo:** classe definida por limites (média ± k desvios) em cada banda; pode deixar pixels sem classe
- **Máxima verossimilhança (MaxVer):** modela cada classe por uma distribuição normal multivariada e atribui o pixel à classe de maior probabilidade
- **Pressuposto da MaxVer:** classes com distribuição aproximadamente normal e amostras suficientes para estimar a covariância

Regiões de decisão

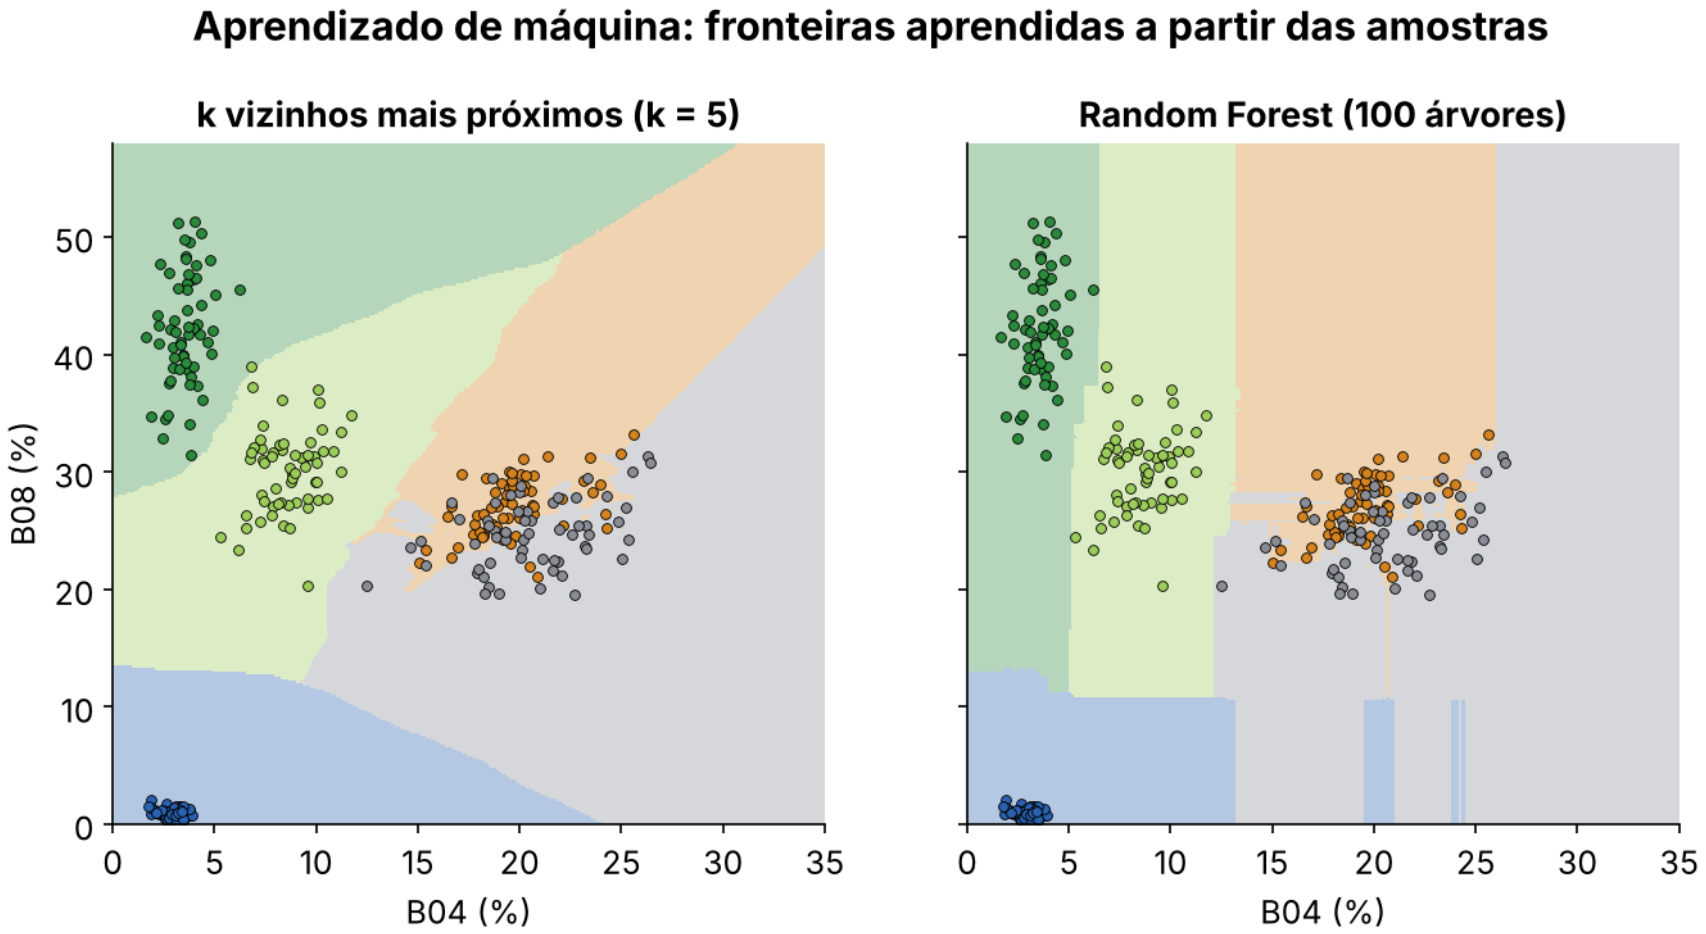


Áreas em branco no paralelepípedo: pixels não classificados. Dados ilustrativos.

Aprendizado de máquina

- **k vizinhos mais próximos (k-NN):** o pixel recebe a classe mais frequente entre as k amostras mais próximas
- **Random Forest:** conjunto de árvores de decisão treinadas com subamostras; a classe final é decidida por votação (BREIMAN, 2001)
- **SVM:** busca a fronteira que maximiza a margem entre as classes
- **GMM (dzetsaka):** modelo gaussiano por classe, princípio próximo ao da máxima verossimilhança
- **Vantagem:** fronteiras flexíveis e uso de muitas variáveis; exige amostras representativas

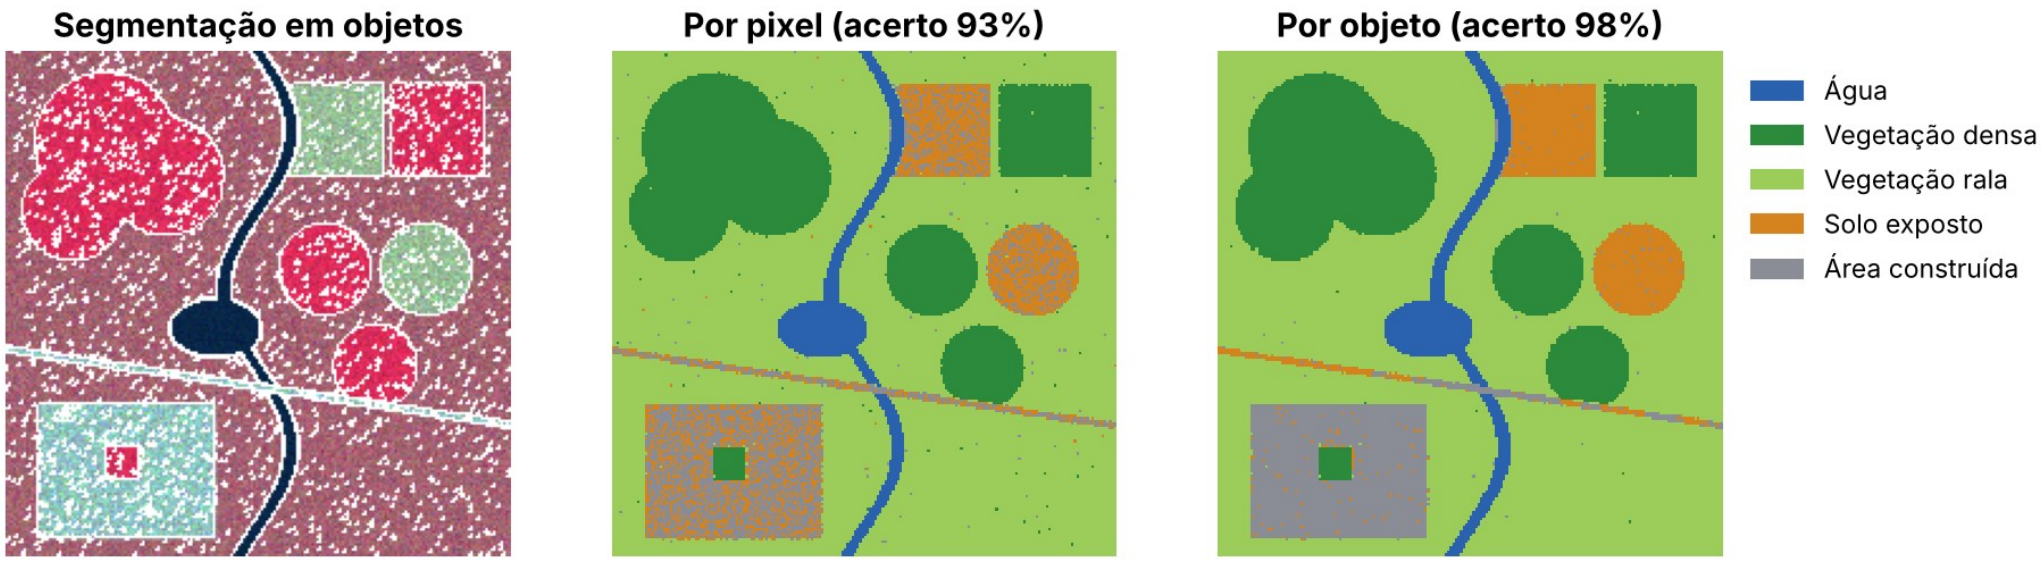
k-NN e Random Forest



Dados ilustrativos.

Pixel × objeto (GEOBIA)

Pixel × objeto: a segmentação reduz o efeito “sal e pimenta”



Crescimento de regiões (5 bandas); máxima verossimilhança com B04 e B08 aplicada ao pixel e à média de cada objeto. Cena sintética.

A análise baseada em objetos agrupa pixels contíguos e semelhantes antes da classificação (BLASCHKE, 2010).

Avaliação da acurácia: matriz de confusão

Matriz de confusão: exatidão global = 93,2% · kappa = 0,88

Classif. \ Ref.	Água	Veg. densa	Veg. rala	Solo	Construída	Total	Exat. usuário
Água	**1.536**	0	0	0	0	1.536	100,0%
Veg. densa	0	**7.587**	62	0	0	7.649	99,2%
Veg. rala	186	68	**23.913**	6	25	24.198	98,8%
Solo	0	0	83	**1.689**	1.498	3.270	51,7%
Construída	17	0	117	664	**2.549**	3.347	76,2%
Total	1.739	7.655	24.175	2.359	4.072	40.000	
Exat. produtor	88,3%	99,1%	98,9%	71,6%	62,6%		

Máxima verossimilhança com B04 e B08 sobre a cena sintética; referência = todos os pixels. Diagonal = acertos.

A matriz de confusão é a base da avaliação da acurácia de classificações (CONGALTON, 1991).

Índices de acurácia

- **Exatidão global:** soma da diagonal ÷ total de pixels avaliados
- **Exatidão do produtor:** acertos da classe ÷ total da referência (complemento: erro de omissão)
- **Exatidão do usuário:** acertos da classe ÷ total classificado na classe (complemento: erro de comissão)
- **Kappa:** concordância descontada a esperada ao acaso (COHEN, 1960); faixas de interpretação em Landis e Koch (1977)
- **Alternativa ao kappa:** discordância de quantidade e de alocação (PONTIUS JR.; MILLONES, 2011)

Síntese

- A classificação converte reflectâncias em classes a partir da separabilidade no espaço de atributos
- A não supervisionada agrupa; a supervisionada aprende com amostras
- Amostras e algoritmo condicionam o resultado tanto quanto a imagem
- Sem avaliação da acurácia, a confiabilidade do mapa é desconhecida

Discussão

- Por que solo exposto e área construída se confundem? Que bandas ajudam a separá-los?
- Quando a classificação não supervisionada é preferível à supervisionada?
- Por que a máxima verossimilhança exige um número mínimo de amostras por classe?
- Como o pixel misto afeta a acurácia em resoluções de 10 m e de 30 m?

Atividade prática 1: preparar imagem e amostras

1. Reabrir a cena Sentinel-2 L2A do Dia 1 (pasta R10m)
2. Criar raster multibanda com B02, B03, B04 e B08 (Raster › Miscelânea › Construir Raster Virtual, bandas separadas)
3. Exibir composição falsa-cor: R = B08, G = B04, B = B03
4. Criar camada vetorial de polígonos com campo inteiro “classe”
5. Digitalizar amostras das cinco classes, distribuídas pela cena (1 água, 2 vegetação densa, 3 vegetação rala, 4 solo exposto, 5 área construída)

Atividade prática 2: classificar com o dzetsaka

1. Instalar o complemento dzetsaka (Complementos › Gerenciar e Instalar Complementos)
2. Indicar o raster multibanda, a camada de amostras e o campo numérico de classe
3. Escolher o algoritmo: GMM (sem dependências) ou RF, SVM e KNN (exigem scikit-learn)
4. Definir as saídas: mapa classificado, mapa de confiança e matriz de confusão, com percentual de amostras reservado para validação
5. Executar e comparar o mapa com a composição falsa-cor

Nomes de menus e opções variam entre versões do dzetsaka: conferir na versão instalada.

Atividade prática 3: avaliar e pós-processar

1. Analisar a matriz de confusão: exatidão global, do produtor, do usuário e kappa
2. Repetir a classificação com outro algoritmo (ex.: GMM e RF) e comparar
3. Inspecionar o mapa de confiança: onde o classificador hesita?
4. Eliminar pixels isolados (Raster › Análise › Peneira)
5. Calcular a área de cada classe e exportar o mapa em layout

Verificar antes: as amostras de validação devem ser independentes das de treinamento.

Discussão da atividade

- Quais classes apresentaram maior omissão e maior comissão? Por quê?
- O resultado mudou entre GMM e Random Forest?
- O mapa de confiança coincide com as áreas de erro?
- Como a data da imagem influencia a confusão entre classes?

Referências (ABNT NBR 6023)

BLASCHKE, T. Object based image analysis for remote sensing. **ISPRS Journal of Photogrammetry and Remote Sensing**, v. 65, n. 1, p. 2-16, 2010. DOI: 10.1016/j.isprsjprs.2009.06.004.

BREIMAN, L. Random forests. **Machine Learning**, v. 45, n. 1, p. 5-32, 2001. DOI: 10.1023/A:1010933404324.

COHEN, J. A coefficient of agreement for nominal scales. **Educational and Psychological Measurement**, v. 20, n. 1, p. 37-46, 1960. DOI: 10.1177/001316446002000104.

CONGALTON, R. G. A review of assessing the accuracy of classifications of remotely sensed data. **Remote Sensing of Environment**, v. 37, n. 1, p. 35-46, 1991. DOI: 10.1016/0034-4257(91)90048-B.

KARASIAK, N. **Dzetsaka Qgis Classification plugin**. [S. l.]: Zenodo, 2016. DOI: 10.5281/zenodo.2552284. Disponível em: https://github.com/nkarasiak/dzetsaka. Acesso em: 13 nov. 2026.

LANDIS, J. R.; KOCH, G. G. The measurement of observer agreement for categorical data. **Biometrics**, v. 33, n. 1, p. 159-174, 1977. DOI: 10.2307/2529310.

MOREIRA, M. A. **Fundamentos do sensoriamento remoto e metodologias de aplicação**. 4. ed. Viçosa: Ed. UFV, 2011.

PONTIUS JR., R. G.; MILLONES, M. Death to Kappa: birth of quantity disagreement and allocation disagreement for accuracy assessment. **International Journal of Remote Sensing**, v. 32, n. 15, p. 4407-4429, 2011. DOI: 10.1080/01431161.2011.552923.

ZANOTTA, D. C.; FERREIRA, M. P.; ZORTEA, M. **Processamento de imagens de satélite**. São Paulo: Oficina de Textos, 2019.